

An aerial map of New York City, showing the dense grid of streets and the surrounding water bodies like the Hudson River and East River. The map is in a muted, sepia-toned color palette.

Optimización de Movilidad Urbana: **Predicción de Tiempos de Viaje en Taxis de NYC**

Proyecto de Data Science - Análisis y Modelado

Autor: Leandro Setti

CODERHOUSE

El Desafío de la Movilidad en NYC

-  **Complejidad:** NYC es un ecosistema denso y caótico.
-  **Incertidumbre:** El tráfico impredecible afecta la planificación.
-  **Objetivo:** Predecir la duración exacta de un viaje usando ML.
-  **Enfoque:** Integrar variables externas: Clima + Feriados + Zonas.





¿Quién se beneficia del modelo?

Pasajeros: Planificación real y reducción de ansiedad.

Apps de Movilidad: Tarifas dinámicas justas y asignación eficiente.

Urbanismo: Detección de zonas críticas y cuellos de botella.

Preguntas de Negocio

- ¿Cuánto "cuesta" en minutos una tormenta en Manhattan?
- ¿Es la distancia un buen predictor en hora pico?
- ¿Cómo cambia el patrón de viaje en un feriado?

Hipótesis 1: Impacto Meteorológico

H0 (Nula): La lluvia NO afecta significativamente la velocidad promedio.

H1 (Alternativa): La lluvia reduce drásticamente la velocidad, especialmente en trayectos cortos (congestión).





Hipótesis 2 y 3: Tiempo y Calendario

Hora Pico: En franjas 8-9 AM y 5-7 PM, la correlación *Distancia vs. Tiempo* cae (el tráfico domina).

Feriados: Se comportan como "fines de semana disfrazados", con menor volumen y mayor velocidad.

Stack Tecnológico y Datos

Datos

Dataset: NYC Taxi Trip Duration (Kaggle/NYC Open Data).

Volumen: 1.458.644 registros originales.

Enriquecimiento



Meteostat: Clima histórico.



Nager.Date: Feriados US.



GeoPandas: Zonas y Distritos.

Metadata

#	Column	Non-Null Count	Dtype
---	--------	----------------	-------

0	id	1432248 non-null	object
---	----	------------------	--------

1	vendor_id	1432248 non-null	int64
---	-----------	------------------	-------

2	pickup_datetime	1432248 non-null	datetime64[ns]
---	-----------------	------------------	----------------

3	dropoff_datetime	1432248 non-null	datetime64[ns]
---	------------------	------------------	----------------

4	passenger_count	1432248 non-null	int64
---	-----------------	------------------	-------

5	pickup_longitude	1432248 non-null	float64
---	------------------	------------------	---------

6	pickup_latitude	1432248 non-null	float64
---	-----------------	------------------	---------

7	dropoff_longitude	1432248 non-null	float64
---	-------------------	------------------	---------

8	dropoff_latitude	1432248 non-null	float64
---	------------------	------------------	---------

9	store_and_fwd_flag	1432248 non-null	object
---	--------------------	------------------	--------

10	trip_duration	1432248 non-null	int64
----	---------------	------------------	-------

11	temp	1431712 non-null	Float64
----	------	------------------	---------

12	prcp	1388957 non-null	Float64
----	------	------------------	---------

13	wspd	1431712 non-null	Float64
----	------	------------------	---------

14	pickup_zone	1432248 non-null	object
----	-------------	------------------	--------

15	pickup_borough	1432248 non-null	object
----	----------------	------------------	--------

16	dropoff_zone	1432248 non-null	object
----	--------------	------------------	--------

17	dropoff_borough	1432248 non-null	object
----	-----------------	------------------	--------

18	dist_haversine	1432248 non-null	float64
----	----------------	------------------	---------

19	dist_manhattan	1432248 non-null	float64
----	----------------	------------------	---------

20	is_holiday	1432248 non-null	int64
----	------------	------------------	-------

21	hour	1432248 non-null	int32
----	------	------------------	-------

22	day_name	1432248 non-null	category
----	----------	------------------	----------

23	speed_kmh	1432248 non-null	float64
----	-----------	------------------	---------

24	condicion_clima	1432248 non-null	object
----	-----------------	------------------	--------


25	flujo_manhattan	1432248 non-null	object
----	-----------------	------------------	--------

26	tipo_dia_completo	1432248 non-null	object
----	-------------------	------------------	--------

Hipótesis Meteorológica

Al analizar el impacto de la lluvia, observamos un fenómeno interesante. Si bien validamos la hipótesis de que la lluvia reduce la velocidad, el gráfico nos muestra que **la congestión base de Nueva York es tan alta que la lluvia no puede empeorarla mucho más en el promedio** (el tráfico ya es lento de por sí).

Sin embargo, el impacto real se ve en los **'mejores casos'**: la lluvia actúa como un 'limitador de velocidad', eliminando la posibilidad de tener viajes rápidos. En días secos, es posible encontrar rutas fluidas; en días de lluvia, esa posibilidad desaparece y la velocidad se estandariza a la baja




Hipótesis Horas Pico

Este mapa de calor valida contundentemente la hipótesis sobre la saturación en horas pico, pero revela que **la ubicación es tan crítica como la hora**.

Validación de Hora Pico: En Manhattan, el tráfico se comporta como un sistema binario. Entre las 8:00 y las 19:00, la velocidad se desploma y se estanca en **11-12 km/h** de manera constante. En esta franja, **el tiempo de viaje deja de ser predecible por la distancia** y pasa a depender puramente de la congestión.

Diferenciación por Distrito: Mientras Manhattan colapsa en horario laboral, distritos como Queens mantienen velocidades superiores a los 20 km/h. Esto sugiere que nuestro modelo predictivo debe tratar los viajes **intra-Manhattan** con una lógica distinta a los viajes hacia los aeropuertos.




Hipótesis Feriados

El gráfico demuestra que un feriado actúa como un 'acelerador' del flujo vehicular. Mientras que en un día laboral promedio nos movemos a **13.7 km/h**, en un feriado la velocidad salta a **16.14 km/h**, superando incluso el promedio de los fines de semana.

Esto significa que si nuestro algoritmo predictivo trata un feriado (ej. un martes de Navidad) como un martes normal, **sobreestimaré el tiempo de viaje**, cometiendo un error grave. Hemos demostrado que es crítico incorporar una fuente de datos externa de feriados para ajustar las predicciones a la baja en estas fechas.

Impacto del Calendario en la Velocidad: Laboral vs. Finde vs. Feriado



Hallazgos Clave y Conclusiones del Proyecto

El Factor Climático

- **Hallazgo:** La lluvia actúa como un "limitador de velocidad".
- **Detalle:** Aunque la velocidad mediana baja levemente, el impacto real es la **desaparición de los viajes rápidos**. La lluvia "aplana" la curva de velocidad, eliminando los outliers positivos (viajes fluidos).
- **Acción para el Modelo:** La variable **precipitación** es crítica para penalizar las predicciones optimistas, reduciendo el error en estimaciones de "mejor caso".

La Saturación Urbana

- **Hallazgo:** Manhattan tiene una "velocidad terminal" de **11-12 km/h** en horario laboral.
- **Detalle:** Entre las 08:00 y las 19:00, la correlación lineal entre *Distancia* y *Tiempo* se rompe debido a la saturación. En esta franja, el tiempo de viaje es función del tráfico, no de los kilómetros.
- **Acción para el Modelo:** Se debe segmentar el entrenamiento o crear *features* de interacción (**`is_manhattan * is_rush_hour`**) para capturar este comportamiento no lineal.

El Efecto Calendario

- **Hallazgo:** Los feriados son **17% más rápidos** que los días hábiles.
- **Detalle:** Contrario a la intuición de "tráfico vacacional", los feriados presentan la mayor fluidez vehicular del año (**16.14 km/h**), superando incluso a los fines de semana.
- **Acción para el Modelo:** Es imperativo integrar una API de feriados (como `Nager.Date`). Tratar un feriado como un día hábil normal introduciría un sesgo sistemático de sobreestimación de tiempo.